

实验作业：NSG 索引性能优化

一、实验背景

近似最近邻搜索 (Approximate Nearest Neighbor, ANN) 是向量数据库的核心算子，被广泛应用于图像检索、推荐系统、检索增强生成 (RAG) 等场景。在主流的 ANN 索引中，**基于邻域图 (proximity graph) 的方法**在大多数公开数据集上同时取得了高召回率与高吞吐，是工业界与学术界的主流路线之一。

NSG (Navigating Spreading-out Graph, 导航扩散图) 是其中的代表性工作。它从一张近似 kNN 图出发，基于 MRNG (Monotonic Relative Neighborhood Graph) 的思想进行边选择 / 剪枝，并引入一个全局导航点 (navigating node) 保证图的连通性与单调可搜索性，从而在索引体积、构图开销与查询性能之间取得了较好的平衡。

本次实验要求大家在阅读论文、读懂源码的基础上，**对 NSG 进行一项实质性的性能优化**，并通过严谨的实验验证你的优化效果。

二、学习目标

完成本实验后，你应当能够：

1. 理解基于近邻图的 ANN 索引的构图与查询原理，能够独立阅读并修改一个真实的 C++ 索引代码库；
2. 掌握 ANN 索引的标准评测方法 (Recall-QPS 曲线、构图开销、内存占用等)，并能设计可复现的对比实验；
3. 针对一个具体的性能瓶颈，提出、实现并验证一项优化 (涉及 SIMD / 缓存 / 预取 / 并行 / 数据布局等系统层面的工程技术)；
4. 撰写一份逻辑清晰、结论可信、可复现的实验报告。

三、实验材料

- NSG 源码: <https://github.com/ZJULearning/nsg>

- **NSG 论文**：Fast Approximate Nearest Neighbor Search With The Navigating Spreading-out Graph, VLDB 2019。 <https://www.vldb.org/pvldb/vol12/p461-fu.pdf>
- **数据集**：使用公开的标准 ANN 基准数据集，至少包含 **SIFT1M**（128 维，1M 底库，10K 查询，附带 groundtruth）和 **GIST1M**（960 维）。
 - SIFT / GIST 下载（TEXMEX）：<http://corpus-texmex.irisa.fr/>
 - 数据格式为 .fvecs / .bvecs / .ivecs，源码中已提供读取代码可直接复用。

注：底库与查询规模可根据机器内存自行调整（如使用 1M 子集），但同一组对比实验必须使用完全相同的数据。

四、必做部分：基线复现

在进行任何优化之前，请先完成基线的复现，作为后续对比的对照组：

1. 在你的机器上成功编译原始 NSG，并跑通「构建 kNN 图 → 构建 NSG → 查询」的完整流程；
2. 在所选数据集上复现 **原始 NSG 的 Recall-QPS 曲线**（通过扫描搜索参数 search_L 得到一系列 (Recall, QPS) 数据点）；
3. 记录构图各阶段的耗时、峰值内存与索引大小；
4. 在报告中**明确记录实验环境**：CPU 型号与核数、内存、编译器及版本、编译选项（如 -O3 -march=native）、线程数、关键构图参数（如 L / R / C）。

提示：缺少可信的基线，后续所有「提升」都无法成立。务必固定随机种子、关闭睿频 / 绑核（如有条件）、多次测量取稳定值，以减少噪声。

五、优化方向（任选其一，鼓励自选）

请从下列两个方向中**任选其一**深入完成。若你有更好的想法，也可以在与任课教师沟通后自拟方向。

方向 A：查询性能优化（单线程）

目标：在**单线程**下，使查询性能（在相同召回率水平下的 QPS）相比原始 NSG **显著提升**。

要点：优化**不得以牺牲召回率为代价**——必须在**同一条 Recall-QPS 曲线**的意义下比较，即在

相同 Recall 处比较 QPS，或整条曲线整体右上方移动。

可参考的切入点（不限于此，鼓励组合）：

- **距离计算加速**：使用 SIMD（SSE / AVX2 / AVX-512）+ FMA 重写 L2 / 内积；注意数据对齐与向量化友好的内存布局；
- **访存与缓存优化**：调整向量与邻接表的存储布局（如向量与邻居 ID 的交错 / 分离存储），提高 cache 局部性，减少 cache miss；
- **预取（prefetch）**：在遍历邻居前对下一批待访问向量 / 邻接表做软件预取，掩盖访存延迟；
- **候选集结构优化**：用更高效的数据结构管理搜索候选池（有序数组 vs 堆），降低插入 / 弹出与查重开销；
- **冗余计算消除**：用 bitset / version array 等高效方式记录已访问节点，避免重复距离计算；
- **图重排序（reordering）**：按搜索访问局部性对节点重新编号（如 BFS / DFS 序、社区划分），提升访存连续性；
- **（进阶）量化**：引入 SQ / PQ 等量化在搜索阶段做粗筛、用原始向量做精排，需谨慎评估对召回率的影响。

方向 B：构图性能优化（多线程）

目标：在多线程下，使 NSG 的构图时间显著下降，并且保证查询性能不回退（构出的图质量不下降）。

要点：必须证明优化后构出的图与基线图质量等价——即两者的 Recall-QPS 曲线基本重合（在合理误差范围内）；不能为了加速而构出更差的图。

可参考的切入点（不限于此）：

- **边选择 / 剪枝阶段并行化**：NSG 的 Link（基于 MRNG 的剪枝）阶段对各节点的处理在只读 kNN 图的前提下高度可并行，是首要的并行对象；
- **负载均衡**：节点的邻居数差异较大，使用 OpenMP schedule(dynamic) 或任务窃取等方式改善负载不均；

- **锁竞争优化**：减少更新反向边 / 共享结构时的锁粒度，或改用原子操作 / 无锁结构；
- **kNN 图构建优化**：构图前置的 kNN 图本身也可并行构建加速优化；
- **(进阶) NUMA 亲和性**：在多路 CPU 上考虑数据与线程的 NUMA 绑定，减少跨节点访存。

报告中需给出**线程数-构图时间**的扩展性曲线（如 1 / 2 / 4 / 8 / ... 线程的加速比），并说明并行效率随核数变化的原因。

六、评测指标与方法

请使用 ANN 领域的标准评测口径，**所有对比必须在相同硬件、相同数据、相同参数空间下进行**：

维度	指标
查询质量	Recall@K（建议报告 K=1、10、100 中的至少一项）
查询性能	单线程 QPS / 平均查询延迟；以 Recall-QPS 曲线 呈现
构图开销	构图各阶段 wall-clock 时间、峰值内存、索引大小
并行扩展性（方向 B）	不同线程数下的构图时间与加速比

评测方法要求：

1. **曲线对比而非单点对比**：通过扫描搜索参数得到多个 (Recall, QPS) 点，绘制曲线后比较，避免「挑一个对自己有利的点」；
2. **控制变量**：每次只改变被研究的因素，其余保持一致；
3. **可复现**：固定随机种子，多次测量取中位数 / 均值，并报告波动；
4. **消融分析**：若你的优化包含多个子项（如同时做了 SIMD + 预取），请分别量化各子项的贡献。

七、组队说明

1. 本实验可单人独立完成，也可最多 2 人组队完成；不接受 3 人及以上的小组。

2. 组队完成的，只需提交一份成果；报告首页须注明两名成员的学号与姓名，并由两人共同对成果负责。
3. 报告中须包含分工说明，明确列出每位成员承担的具体工作（例如：A 负责距离计算的 SIMD 优化与查询路径改造，B 负责评测脚本、数据集准备与实验分析）。
4. 组队不等于工作量减半：2 人小组的预期产出应不低于、并适当高于单人完成的标准（如更充分的消融实验、覆盖更多数据集，或在所选方向上做更深入的优化）。
5. 成绩评定：原则上组内同分；若分工严重失衡或存在明显搭便车情况，教师有权根据实际贡献给出差异化分数。
6. 学术诚信：组内可充分协作交流，但不同小组之间不得共享代码或实验数据，违者按抄袭处理。

八、提交要求

请打包提交以下内容（命名格式：学号_姓名_NSG.zip）：

1. **源代码**：基于原始 NSG 的修改版本，保留可编译运行的状态；附 README，写清编译命令、运行命令与依赖；
2. **实验报告 (PDF)**，建议包含：
 - 选题方向与优化思路（你认为瓶颈在哪里，为什么这样改）；
 - 关键实现说明（核心改动 + 必要的代码片段，不必贴大段源码）；
 - 实验设置（环境、数据、参数）；
 - 实验结果（Recall-QPS 曲线、构图时间、内存等图表）与分析；
 - 结论与局限 / 未来改进；
3. **复现脚本**：能够一键或按步骤复现报告中关键结果的脚本 / 命令。
4. **截止时间**：2026 年 6 月 26 日 23:59:59 之前；超时将视为未提交。
5. **发送邮箱**：advdb_ug2026@163.com。
6. **建议进度**：第 1 周完成论文阅读 + 源码编译 + 基线复现；第 2 周确定方向并实现优化；最后阶段完成评测与报告撰写。

九、评分标准（满分 100）

项目	分值	说明
基线复现与环境记录	15	基线可复现、环境与参数记录完整
优化实现	30	实现正确、与所选方向相符、有一定工程深度
性能提升效果	25	在严谨口径下确有显著提升，且无召回 / 质量回退
评测严谨性	15	曲线对比、控制变量、多数据集 / 消融、可复现
报告质量	15	思路清晰、图表规范、分析有洞见

关于「显著提升」：不设统一硬性阈值（高度依赖硬件与基线实现质量），重点考察优化思路的合理性与实验论证的严谨性。一个提升 15% 但分析透彻、归因清楚的工作，优于一个号称提升 2 倍却无法复现、口径混乱的工作。

十、注意事项

- **学术诚信**：可以参考公开资料与开源实现，但必须独立完成自己的优化与实验，并在报告中**注明所有参考来源**。直接照搬他人代码而不加说明、或伪造 / 篡改实验数据，按学术不端处理。
- **结果可信优先**：测量噪声、未控制的变量、过拟合到单一参数点，都会让「提升」失去意义。宁可提升幅度小但扎实可复现，不要追求好看但站不住脚的数字。
- **遇到困难及时沟通**：编译环境、数据集获取、评测口径等问题可在课程答疑渠道提出。

参考资料

1. C. Fu, C. Xiang, C. Wang, D. Cai. Fast Approximate Nearest Neighbor Search With The Navigating Spreading-out Graph. PVLDB 12(5), 2019.
2. NSG 源码仓库: <https://github.com/ZJULearning/nsg>
3. ANN-Benchmarks (评测方法与数据集参考): <https://ann-benchmarks.com/>
4. TEXMEX 数据集: <http://corpus-texmex.irisa.fr/>